

UZLEGAL-AI

Apparat bahosi

Bu kompyuter loyihani ko'tara oladimi — o'lchangan raqamlar

Muallif: Shokirjon Madaminov (ShokirjonMK · MKdev)

Aloqa: @ceoNeuron

Sana: 2026-08-12

Repo: github.com/ShokirjonMK/uzlegal-ai

20 — Apparat bahosi: bu kompyuter loyihani ko'tara oladimi

Sana: 2026-08-13 · Usul: taxmin emas, shu mashinada o'lchangan

1. Qisqa javob

Maqsad	Baho
Ishlab chiqish va tadqiqot	✅ A'lo — talabdan ortiq
Bir foydalanuvchi uchun demo	✅ Ishlaydi, lekin sekin (60–90 s)
Yopiq beta (10–30 foydalanuvchi)	⚠️ Chegarada — navbat paydo bo'ladi
Ishlab chiqarish (100+ foydalanuvchi)	❌ Yetmaydi — GPU bitta va kichik
12B modelni fine-tuning qilish	❌ Mumkin emas — VRAM yetmaydi
4B modelni fine-tuning qilish	✅ Mumkin

Yagona to'siq — 8 GB VRAM. Qolgan hamma narsa ortig'i bilan yetarli.

2. Apparat

Komponent	Qiymat	Baho
CPU	Intel i7-14700KF · 20 yadro / 28 oqim	✅ Kuchli
RAM	47.8 GB DDR5-5600	✅ Loyiha mo'ljallagan M4 24 GB dan 2x
GPU	NVIDIA RTX 4060 Ti · 8 GB VRAM · CUDA 13.1	⚠️ Tor joy
Disk	E: 666 GB · D: 439 GB · C: 166 GB bo'sh	✅ Ortig'i bilan
OS	Windows 11 Pro	✅

Tayyor dasturiy ta'minot: Ollama 0.18.2 (gemma3:12b , gemma3:27b , gemma3:4b , qwen3.5 va boshqalar allaqachon yuklangan), Docker 28.3.3, Python 3.13, Node 22.15, Git 2.53.

3. O'lchangan tezliklar

Bularning hammasi **shu mashinada**, shu sessiyada olingan.

3.1 Embedding (BGE-M3, indeks qurish)

Qurilma	Tezlik	8 636 bo'lak uchun
CUDA	33 bo'lak/s	~4.4 daqiqa
CPU (20 yadro)	1.4 bo'lak/s	~100 daqiqa

GPU CPU dan **24 barobar** tez. Indeks qurish — GPU ning eng foydali ishi.

3.2 Qidiruv (modelsiz)

Metrika	Qiyamat	Maqsad
Median	204 ms	—
p95	279 ms	600 ms

Qidiruv **maqsaddan tez**. Bu mashina uchun umuman muammo emas.

3.3 Model javobi (gemma3:12b, Ollama)

Rejim	O'lchandi	Maqsad
simple	61–92 s	~5 s

Sabab aniq: `gemma3:12b` 4-bit da **8.1 GB**, VRAM esa **8.0 GB**.

Model to'liq sig'maydi va bir qismi CPU ga tushadi. Har token uchun ma'lumot PCIe orqali borib-keladi.

3.4 Reranker (CPU da)

Median	32 044 ms
p95	41 185 ms

Amalda ishlatib bo'lmaydi. Lekin bu ahamiyatsiz — reranker o'lchov

asosida **o'chirilgan** (`reports/retrieval-rerank-2026-08-12.md`): u

Recall@10 ni 8 punktga tushirardi.

3.5 Korpus yuklash

863 hujjat	~4.8 soat
Tezlik	20 s/hujjat

Bu mashina cheklovi emas — robots.txt dagi Crawl-delay: 20 .

Eng kuchli serverda ham xuddi shuncha vaqt oladi.

4. Tor joy: 8 GB VRAM

Butun muammo bitta raqamda.

Model	Hajm (4-bit)	8 GB VRAM ga sig'adimi	Kutilayotgan tezlik
gemma3:4b	3.3 GB	✓ To'liq	tez (~5–10 s)
qwen3.5	6.6 GB	✓ Zichroq	tez
gemma3:12b ⭐	8.1 GB	✗ Chegarada	61–92 s
gemma3:27b	17 GB	✗ Yo'q	juda sekin
gpt-oss:120b	65 GB	✗ Yo'q	ishlamaydi

⭐ — ADR-001 da tanlangan model.

Nima uchun 12B sekin

VRAM 8.0 GB, model 8.1 GB. Ustiga KV-cache va kontekst kerak (huquqiy kontekst ~6 000 token). Natijada modelning bir qismi tizim xotirasida qoladi va har token uchun PCIe orqali ko'chiriladi.

Bu arifmetik cheklov — kod bilan hal qilinmaydi.

Uchta yo'l

Yo'l	Tezlik	Sifat	Xarajat
A. gemma3:4b ga o'tish	~5–10 s	pastroq	0
B. 16–24 GB GPU	~8–12 s	to'liq	~\$800–1600
C. Server (A100/H100)	~6 s, parallel agentlar	to'liq	oyiga ~\$350–1100

A yo'li bitta buyruq bilan sinaladi:

```
uzlegal models use ollama-gemma3-4b
uzlegal eval safety --suite traps-30
```

Agar 4B da traps-30 natijasi 12B nikidan sezilarli past bo'lmasa — bu mashinada beta uchun yetarli.

5. Nima uchun RAM va CPU muammo emas

Loyiha docs/02 da 24 GB unified memory (MacBook Air M4) uchun mo'ljallangan va byudjet shunga qurilgan (RESERVED_GB = 9.0). Bu mashinada 47.8 GB bor — ya'ni ikki barobar. Indeks qurish paytida eng yuqori sarf 40.9 GB ni ko'rsatdi va u ham bimalol sig'di. 20 yadro esa parsing, chunking va BM25 uchun ortig'i bilan yetarli: 863 hujjatni chunklash bir necha soniya oladi.

6. Loyihaning uchta rejimi va ularning talabi

Rejim	Nima kerak	Bu mashinada
Ma'lumot quvuri (kb sync , index build)	Disk + GPU	✓ A'lo
Qidiruv (search , /v1/search)	Faqat embedding	✓ A'lo (204 ms)
To'liq maslahat (ask , /v1/consult)	LLM inference	⚠ Sekin (60–90 s)

Muhim xulosa: loyihaning ikkita rejimidan uchtasi bu mashinada mukammal ishlaydi. Faqat model javobi sekin, va u ham konfiguratsiya bilan hal qilinadi.

7. Nechta foydalanuvchini ko'taradi

GPU bitta va model navbat bilan javob beradi (Ollama parallel so'rovlarni ketma-ket bajaradi).

Foydalanuvchi	Kutish vaqti	Baho
1	60–90 s	✅ Maqbul
5 (bir vaqtda)	5–7 daqiqa	⚠️ Chegarada
20 (bir vaqtda)	20–30 daqiqa	❌ Yaramaydi

`gemma3:4b` bilan bu raqamlar taxminan **6–10 barobar** yaxshilanadi.

Qidiruv (`/v1/search`) esa modelsiz ishlaydi va **yuzlab** so'rovni

bemalol ko'taradi — bu muhim, chunki foydalanuvchilarning katta qismi

aslida qidiruv qiladi, maslahat emas.

8. Fine-tuning imkoniyati

Model	QLoRA uchun VRAM	Bu mashinada
12B	~10–12 GB	❌ Yetmaydi
4B	~5–6 GB	✅ Sig'adi

Ustiga trening kodi hozir `mlx_lm` ga bog'langan — u **faqat macOS**.

CUDA yo'li (`peft` + `transformers`) hali yozilmagan (docs/18 § 5).

Ya'ni bu mashinada fine-tuning uchun **ikkita ish** kerak: kod yo'li va

kichikroq model. Yoki bulut GPU (~\$50, docs/11 bahosi).

9. Ishga tushirish rejasi — shu mashinada

Bugun ishlaydigan holat

<code>uzlegal doctor</code>	<code># muhit tekshiruvi</code>
<code>uzlegal search "sinov muddati"</code>	<code># 204 ms</code>
<code>uzlegal serve</code>	<code># API + Web</code>

Qidiruv, hujjat tahlili va bilim bazasi — hammasi tayyor.

Beta uchun tavsiya

1. `gemma3:4b` ga o'ting va `traps-30` ni qayta o'lchang.

UzLegal-AI · Shokirjon Madaminov (@ceoNeuron) · 2026-08-12

Sifat farqi kichik bo'lsa — 6–10× tezlik tekinga keladi.

1. **Rate-limit ni pasaytiring** (`per_ip_minute`) — navbat cho'zilib ketmasin.

1. **Qidiruvni alohida targ'ib qiling** — u tez va modelsiz ishlaydi.

Ishlab chiqarish uchun

Repo egasi serverga ega. `deploy/docker-compose.server.yaml` tayyor va

`openai` backend orqali vLLM ga ulanadi. Serverning GPU si 24 GB dan

katta bo'lsa — `gemma3:12b` to'liq tezlikda ishlaydi.

10. Xulosa

Bu mashina loyiha uchun **kutilganidan yaxshi**: RAM ikki barobar, CPU kuchli, disk yetarli, GPU esa ishlaydi va embeddingda 24× tezlik beradi.

Yagona cheklov — **VRAM hajmi**, va u faqat bitta narsaga ta'sir qiladi: 12B modelning javob tezligiga. Bu ham ****konfiguratsiya masalasi****, arxitektura masalasi emas — model almashtirish bitta buyruq (`uzLegal models use`), va ADR-003 dagi «bitta yadro, almashadigan model» qarori aynan shuni ko'zlagan edi.

Ishlab chiqish va beta uchun: yetarli.

Ishlab chiqarish uchun: server kerak — u repo egasida bor.