

UZLEGAL-AI

Fine-tuning hisoboti

Modelni maxsus o'qitish: nima qilindi, nima qilinmadi va nega

Muallif: Shokirjon Madaminov (ShokirjonMK · MKdev)

Aloqa: @ceoNeuron

Sana: 2026-08-12

Repo: github.com/ShokirjonMK/uzlegal-ai

18 — Fine-tuning hisoboti

Sana: 2026-08-12 · **Savol:** modelni fine-tuning qilish qanday bo'ldi, nimalar qilindi?

1. Qisqa javob

Fine-tuning HECH QACHON bajarilmagan. Bitta ham adapter o'qitilmagan, bitta ham trening namunasi tayyorlanmagan.

Mavjud narsa — **quvur kodi**. U yozilgan, lekin bugungi kunga qadar **bir marta ham uchidan-uchgacha ishlatilmagan**, va tekshirganimda birinchi qadamning o'zi yiqilardi (§ 4).

Nima	Holat
Trening ma'lumoti (<code>data/sft/samples.jsonl</code>)	❌ yo'q
O'qitilgan adapterlar (<code>adapters/</code>)	❌ papka umuman yo'q
<code>configs/models.yaml</code> → <code>adapters:</code>	❌ <code>{}</code> — bo'sh
Trening yurgizilgan logi	❌ yo'q
Quvur kodi	✅ bor (~430 satr)
Giperparametrlar (<code>configs/training/role-lora.yaml</code>)	✅ yozilgan va asoslangan

Ya'ni hozirgi tizimda rollar farqi faqat PROMPTDAN keladi.


2. Reja nima edi

`ADR-003` va `docs/05` bo'yicha: **bitta baza model + beshta LoRA adapter.**

Element	Qiymat	Nega shunday
Baza model	Gemma-3-12B (4-bit)	ADR-001 da o'lchab tanlangan: 3.77/5, o'zbek tili 4.82/5
Adapter usuli	LoRA, rank 16	Rol adapteri yangi bilim o'rgatmaydi — bilim RAG dan keladi. Adapter faqat <i>qanday gapirishni</i> o'zgartiradi
Alpha	32 (= 2 × rank)	Amaliyotdagi standart nisbat
Maqsad modullar	q_proj, k_proj, v_proj, o_proj	Faqat attention. MLP qo'shilsa adapter uch barobar kattalashadi
Adapter hajmi	~40 MB	Beshtasi 200 MB; baza model xotirada bitta nusxada qoladi
Epoch / LR	3 / 1e-4	docs/05 § 5

Nima uchun beshta model emas: 24 GB xotirada beshta 12B model sig'maydi (~40 GB kerak), adapterlar esa 8.2 GB da hammasi joylashadi.

3. Quvur qanday ishlashi kerak edi



Qadam	Buyruq	Kodi bormi
1. Urug' savollar	uzlegal train seed --role advocate	✅ (bugun tuzatildi)
2. Sintetik javob generatsiyasi	—	⚠️ CLI da yo'q
3. Avtomatik filtrlar	check_sample(), filter_samples()	✅
4. Yurist tekshiruvi	uzlegal train verify	✅
5. Statistika	uzlegal train stats	✅
6. LoRA trening	uzlegal train lora --role advocate	✅ (lekin § 5 ga qarang)

Muhim himoya qoidasi — to'g'ri yozilgan

```
configs/training/role-lora.yaml :
```

```
data:
  require_verified: true
  min_samples: 500
```

Tekshirilmagan namuna treningga **tushmaydi**, va buni chetlab o'tish uchun `allow_unverified=True` ni ataylab yozish kerak. Izohda sabab ham bor:

Tekshirilmagan yuridik data modelni **ishonch bilan xato qilishga** o'rgatadi va bu tekshirilmagan modeldan yomonroq.

Bu to'g'ri qaror va u kodda mustahkamlangan.

4. Bugun topilgan nuqson: `train seed` yiqilardi

Quvurni sinab ko'rganimda **birinchi qadamning o'zi ishlamadi**:

```
TypeError: Object of type Chunk is not JSON serializable
```

`seed_questions()` `Chunk` obyektining **o'zini** qaytarardi, CLI esa uni `json.dumps` bilan faylga yozmoqchi bo'lardi.

Nega testlar tutmadi. Mavjud testlar natijaning faqat `question` va `role` maydonlarini tekshirardi va uni **hech qachon JSON ga yozmasdi**:

```
seeds = list(seed_questions(chunks, "jurist"))
assert all(s["role"] == "jurist" for s in seeds) # o'tadi
```

Bu — bugun uchragan naqshning yana bir ko'rinishi: ****kod bor, test bor, lekin ikkalasi ham haqiqiy yo'ldan o'tmaydi.****

Tuzatildi: endi `ContextRef` ko'rinishida serializatsiya qilinadi va modda havolasi (`chunk_id` , `doc_title` , `article`) saqlanadi. JSON ga yozishni tekshiradigan test qo'shildi.

```
✓ 5 urug' savol → data/sft/advocate/seeds.jsonl
```

⚠ Bu tekshirilmagan sintetik material. Yurist tekshiruvsiz treningga ishlatilmaydi.

5. Ikkinchi to'siq: trening faqat macOS'da mumkin

`training/lora.py` treningni tashqi buyruqqa uzatadi:

```
command = [sys.executable, "-m", "mlx_lm.lora", "--model", ...]
```

`mlx_lm` — **faqat Apple Silicon**. Ya'ni:

- bu Windows + RTX 4060 Ti mashinada trening **umuman ishga tushmaydi**;
- `deploy/` dagi Linux + GPU serverda ham ishlamaydi.

Bu **aynan inference qatlamidagi muammoning ikkinchi nusxasi** — o'sha

muammoni bugun `openai_backend.py` bilan hal qildim ([docs/16](#) § 2).

Trening tomonida u hali **hal qilinmagan**.

Yechim: `peft` + `transformers` + `bitsandbytes` orqali CUDA yo'li

qo'shish. Mavjud `TrainingConfig` va tekshiruvlar o'zgarmaydi — faqat

bajaruvchi qism almashadi, xuddi `InferenceBackend` dagi kabi.

⚠ **8 GB VRAM cheklovi.** 12B modelni QLoRA bilan o'qitish uchun ~10–12 GB VRAM kerak. Bu mashinada 12B **o'qitib bo'lmaydi**. Realistik variantlar: `gemma3:4b` (sig'adi) yoki bulut GPU (A100 — [docs/11](#) byudjetida ~\$50).

6. Asosiy to'siq — texnik emas

Quvur tuzatilsa ham, trening **boshlanmaydi**, chunki tekshirilgan

ma'lumot yo'q.

Talab	Miqdor	Manba
Tekshirilgan namuna	2 000 (400 × 5 rol)	docs/11 Faza 3
Yurist vaqti	~1 500 soat	docs/14 § 6
Gold set	500 savol	docs/11 Faza 3

docs/11 R1 riskida bu ochiq aytilgan:

Agar ekspert topilmasa — bu faza to'xtaydi va butun loyiha sifati cheklanadi.

7. Fine-tuningsiz nima yo'qotiladi

docs/11 § 4 ning o'zi shunday deydi:

Bu bosqich tugagach tizim **allaqachon foydali** — fine-tuningsiz, RAG + baza model bilan ~70% aniqlik.

Xususiyat	Promptdan (hozir)	Adapterdan (reja)
Rol farqi	✔ ishlaydi	✔ kuchliroq
Rol sodiqligi	o'lchanmagan	maqsad $\geq$ 90%
Format rioyasi	gate bilan majburlanadi	maqsad $\geq$ 98%
Iqtibos odati	promptda talab qilinadi	o'rgatiladi
Kechikish	bir xil	bir xil
Xotira	bir xil	+200 MB

Xulosa: adapterlar sifat oshiradi, lekin ular BLOKER emas.

8. Tavsiya: adapterlarni v1.0 dan KEYINGA qoldirish

Sabablari:

1. **1 500 soat yurist vaqti** — loyihaning eng qimmat resursi. Uni adapterga sarflashdan oldin ****haqiqiy foydalanuvchi qaysi savollarni berishini**** bilish kerak.

1. Hozir korpus 20 kodeks. Adapter o'qitilsa, korpus kengaygach u **qayta o'qitilishi** kerak bo'ladi.

1. Bir xil yurist vaqtini **gold set** (500 savol) ga sarflash ko'proq foyda beradi: u sifatni **o'lchash** imkonini beradi, ya'ni keyingi har bir qaror taxminga emas, raqamga tayanadi.

1. **retrieval-gold-v1** hozir atigi **36 holat** — statistik jihatdan

zaif. Uni 200+ ga kengaytirish adapterdan **arzonroq va tezroq** natija beradi.

Taklif qilinadigan tartib

#	Ish	Yurist vaqti	Natija
1	<code>retrieval-gold-v1</code> → 200 holat	~20 soat	O'lchov ishonchli bo'ladi
2	<code>smoke-50</code> → <code>gold-300</code>	~60 soat	Uchidan-uchgacha sifat o'lchanadi
3	Beta foydalanuvchilardan real savollar	0 soat	Haqiqiy taqsimot ma'lum bo'ladi
4	Shundan keyin rol datasetlari	~1 500 soat	Adapterlar

1–3 qadamlar **80 soat** oladi va ular 4-qadamni ancha samaraliroq qiladi: dataset haqiqiy savollar asosida tuziladi, taxmin asosida emas.

9. Bugun bajarilgan ish

#	Ish
1	Fine-tuning holati to'liq tekshirildi va hujjatlashtirildi
2	<code>train seed</code> yiqilishi tuzatildi — quvurning birinchi qadami endi ishlaydi
3	JSON serializatsiyasini tekshiradigan test qo'shildi (regressiya qaytmasin)
4	Trening yo'lidagi platforma cheklovi aniqlandi va yozildi (§ 5)
5	8 GB VRAM da 12B o'qitib bo'lmasligi hisoblandi

Bajarilmagan va nega: haqiqiy trening yurgizilmadi — tekshirilgan ma'lumot yo'q va uni yaratish yurist ekspertni talab qiladi. Sintetik, tekshirilmagan ma'lumot bilan adapter chiqarish esa loyihaning o'z qoidasiga zid (`require_verified: true`) va u modelni ****ishonch** bilan xato qilishga****** o'rgatardi.